

---

Explicaciones para un recomendador de música basadas  
en datos enlazados

Title in English (defined in Cascaras\cover.tex)

---



Trabajo de Fin de Grado  
Curso 2019–2020

Autor

Adrián Garrido Sierra  
Diego Sánchez Muniesa

Director

Guillermo Jiménez Díaz  
Marta Caro Martínez

Grado en **Ingeniería Informática**

Facultad de Informática

Universidad Complutense de Madrid



Explicaciones para un recomendador de  
música basadas en datos enlazados  
Title in English (defined in  
Cascaras\cover.tex)

Trabajo de Fin de Grado en **Ingeniería Informática**  
Departamento de **XXXXXXXXXXXXXX**

**Autor**  
Adrián Garrido Sierra  
Diego Sánchez Muniesa

**Director**  
Guillermo Jiménez Díaz  
Marta Caro Martínez

Convocatoria: *Febrero/Junio/Septiembre 2020*  
Calificación: *Nota*

Grado en **Ingeniería Informática**  
Facultad de Informática  
Universidad Complutense de Madrid

**DIA de MES de AÑO**



# Dedicatoria

*A Pedro Pablo y Marco Antonio, por crear TeXiS  
e iluminar nuestro camino*



# Agradecimientos

A Guillermo, por el tiempo empleado en hacer estas plantillas. A Adrián, Enrique y Nacho, por sus comentarios para mejorar lo que hicimos. Y a Narciso, a quien no le ha hecho falta el Anillo Único para coordinarnos a todos.





# Resumen

## **Explicaciones para un recomendador de música basadas en datos enlazados**

Un resumen en castellano de media página, incluyendo el título en castellano. A continuación, se escribirá una lista de no más de 10 palabras clave.

### **Palabras clave**

Máximo 10 palabras clave separadas por comas



# Abstract

## **Title in English (defined in Cascaras\cover.tex)**

An abstract in English, half a page long, including the title in English. Below, a list with no more than 10 keywords.

## **Keywords**

10 keywords max., separated by commas.



# Índice

<b>1. Introducción</b>	<b>1</b>
1.1. Motivación . . . . .	1
1.2. Objetivos . . . . .	2
1.3. Plan de trabajo . . . . .	3
<b>2. Estado de la Cuestión</b>	<b>5</b>
2.1. Conceptos sobre el ámbito . . . . .	5
2.2. SPARQL . . . . .	7
2.3. WikiData . . . . .	7
<b>3. Explicaciones</b>	<b>9</b>
3.1. Explicaciones de la canción . . . . .	11
3.2. Explicaciones compartidas por Artista y Canción . . . . .	12
3.3. Explicaciones compartidas del Artista y los Miembros . . . . .	15
3.4. Explicaciones compartidas en el Artista, Miembro, Género y Canción . . . . .	16
3.5. Propiedades propias del artista o grupo . . . . .	17
3.6. Explicaciones basadas en el género . . . . .	18
3.6.1. Subgenre . . . . .	19
<b>4. Diseño de la interfaz de explicaciones</b>	<b>21</b>
4.1. Diseño del grafo . . . . .	21
4.2. Diseño básico de la interfaz . . . . .	23
4.3. Diseño avanzado . . . . .	24
<b>5. Implementación</b>	<b>27</b>
5.1. Procesamiento y manejo de la muestra . . . . .	27
5.2. Estudio del dataset . . . . .	28
5.3. Arquitectura de la aplicación . . . . .	29
<b>6. Conclusiones y Trabajo Futuro</b>	<b>31</b>
6.1. Trabajo futuro . . . . .	31
<b>7. Introduction</b>	<b>33</b>
<b>8. Conclusions and Future Work</b>	<b>35</b>

Bibliografía	37
A. Título del Apéndice A	39
B. Título del Apéndice B	41

# Índice de figuras

2.1. Ejemplo de grafo siguiendo el modelo RDF . . . . .	7
3.1. Ejemplo de misma relación en distintos niveles . . . . .	10
3.2. Ejemplo de explicación por artista . . . . .	11
3.3. Ejemplo de explicación por álbum . . . . .	11
3.4. Ejemplo de explicación por década . . . . .	12
3.5. Ejemplo de explicación por single . . . . .	12
3.6. Ejemplo Relaciones que pueden tener artistas por premios . . . . .	13
3.7. Ejemplo de explicación por premio . . . . .	14
3.8. Ejemplo de explicación por género . . . . .	14
3.9. Ejemplo de explicación por idioma . . . . .	15
3.10. Ejemplo de explicación por compañía discográfica . . . . .	15
3.11. Ejemplo de explicación por Location of Formation . . . . .	16
3.12. Ejemplo de explicación por país de origen . . . . .	16
3.13. Ejemplo de explicación por influencia . . . . .	17
3.14. Ejemplo de explicación por integrantes . . . . .	18
3.15. Ejemplo de explicación por tipo de voz . . . . .	18
3.16. Ejemplo de explicación por Subgénero . . . . .	19
4.1. Primer diseño de la interfaz web . . . . .	22
4.2. Segundo diseño de la interfaz web . . . . .	23
4.3. Tercer diseño de la interfaz web . . . . .	24
4.4. Grafo de explicaciones lejanas . . . . .	25
5.1. Gráfico resultado del estudio de géneros . . . . .	28





# Índice de tablas



# Introducción

Desde el desarrollo de internet como una red global, siempre ha albergado grandes cantidades de documentos e información escrita. A medida que fue creciendo, hubo que encontrar distintas maneras de organizar esa información para que pudiera ser utilizada como un servicio a cualquier usuario. La Web Semántica, cuyas características explicaremos más tarde, es uno de los métodos que toda la red global de internet pudo adaptar a la hora de darle un sentido y una utilidad a esa información.

Básicamente, la Web Semántica trata de enlazar toda esa información con tal de darle contexto y accesibilidad. Para ello adopta el método de Linked Data, el cual haciendo referencia a su propio nombre nombre, conecta o une distintos datos estableciendo una relación. El principal objetivo de todo esto es que los ordenadores puedan navegar y acceder a la mayor parte de los datos almacenados en internet para que estos sean útiles y no queden perdidos en un mar de información.

Hay varias maneras de poder organizar y conectar todo ese contenido conocidas como sistemas ontológicos. La ontología es una rama filosófica que estudia los entes y sus conexiones y aquí es aplicada en su punto más técnico. El método ontológico que nosotros usaremos es el modelo RDF, uno de los más usados y extendidos.

Es mediante este concepto como los motores de búsqueda pueden ser ayudados por esta tecnología, ya que dotamos a las máquinas de la capacidad para navegar sobre esas relaciones y entender datos que nosotros requerimos o que podrían sernos útiles.

## 1.1. Motivación

Como ya hemos comentado, la Web Semántica es una manera de mejorar la conexión entre los datos guardados en la red, haciendo que internet sea más útil y accesible para las personas. Se trata de un método que permite que navegar por la red sea más intuitivo y reduce la cantidad de información que acaba volviéndose inaccesible para aquellos usuarios para los que resulta relevante.

El problema es que es una práctica que aún no está lo bastante extendida para que suponga un verdadero avance en nuestra forma de relacionarnos con la red, pues requiere

hacer cambios en la forma en que se almacena la información. En este trabajo intentaremos mostrar el potencial de la Web Semántica

Nuestro proyecto utilizará todo este sistema en el que colaboran distintas metodologías y lo orientará a la conexión y relación de temas musicales. De esta forma estamos especializando las opciones que nos proporciona la Web Semántica en un sentido útil y creativo.

La idea principal es poder recoger todas las conexiones que aparezcan entre toda la información que podamos recoger sobre cada uno de los dos temas musicales o canciones, indagando en un punto sistematizado por el concepto de Linked Data y con formato RDF. Para ello, deberemos estudiar ese ente y todos los relacionados; artista que interpreta la canción, su género musical, los integrantes de su grupo, su sello discográfico, etc. y a su vez las relaciones entre estos, hasta disponer de suficientes conexiones que nos puedan asegurar que esas dos canciones tienen o no algo que ver.

Una vez tengamos toda esa información, la mostraremos gráficamente en una aplicación web de forma que una persona pueda ver y comprender todas esas conexiones con un manejo sencillo de la misma. Para ello estudiaremos diversas librerías gráficas y escogeremos aquella que pueda adaptarse de mejor manera a nuestras necesidades, ya que deberán ser capaces de representar nodos y aristas conforme a nuestra información recopilada.

## 1.2. Objetivos

Los objetivos principales de este trabajo son los siguientes:

- Demostrar la potencia y las conexiones que se pueden llegar a crear entre dos elementos usando el formato RDF en el contexto de la Web Semántica. La Web Semántica es un concepto que abarca muchísima información con conexiones constantes que no para de crecer. Queremos adaptarnos a ese sistema y aplicarlo a un dominio con el que estuviésemos cómodos y despertara nuestro interés.
- Establecer una relación entre dos canciones que, a priori, una persona no podría obtener sin hacer un estudio amplio de ello, empleando para ello explicaciones propias que compartan esas dos canciones. Y, sobre todo, intentar relacionar canciones que no sean tan parecidas musicalmente pero compartan otros elementos que puedan causar más curiosidad.
- Crear una aplicación web que pueda tener un uso habitual en la vida cotidiana y que aporte nuevos conocimientos a los posibles usuarios que la utilicen.
- Utilizar distintas tecnologías de forma que tengamos un resultado final operativo y simple para que cualquier usuario, tenga o no experiencia en el manejo de aplicaciones, sea capaz de usarlo.

- Trabajar con un dominio durante todo el proyecto que nos apasiona tanto a nosotros como a la mayoría de las personas como es la música, ya que al fin y al cabo la aplicación final recopila datos sobre canciones que un usuario no podría saber sin hacer un estudio previo.

### 1.3. Plan de trabajo

El punto inicial del proyecto fue estudiar todas las nueva tecnologías nuevas y herramientas que íbamos a necesitar, al menos, para el proceso de obtención y estudio los datos.

Primeramente hicimos una pequeña limpieza del dataset, ya que había valores sucios y nulos. Hicimos unas pequeñas agrupaciones, por popularidad y por género. La popularidad porque las canciones más populares serían las que estarían más documentadas en Wikidata y el género debido a que queríamos saber qué tipo de canciones predominaban en nuestra muestra.

Más tarde comenzamos a ejecutar pequeñas consultas con el sistema RDF en la herramienta propia de Wikidata. Aquí aprendimos en que se diferenciaban las consultas que más tarde usaríamos en nuestra la librería del propio SPARQL. En este punto ya pudimos observar la cantidad de información que podíamos obtener con una simple consulta y a la vez los datos tan específicos que también nos daba la oportunidad de conseguir, dándonos cuenta de la potencia de este lenguaje.

Una vez obtuvimos cierta soltura con Wikidata y las nuevas tecnologías que íbamos a usar, pasamos a buscar una librería lo suficientemente completa y potente que pudiese servirnos para ejecutar las consultas deseadas y en un tiempo aceptable. Después de estudiar algunas opciones, finalmente escogimos SPARQLWrapper debido a que nos permitía la ejecución de todo tipo de consultas y además nos facilitaba la conexión al punto de obtención.

Continuando con el proceso comenzamos el algoritmos y el conjunto de clases y librerías que nos permitirían obtener los datos y establecer las conexiones necesarias para dotar de una posible relación a dos canciones. Tuvimos varias versiones, ya que siempre incluíamos nuevas partes del código, nuevas propiedades a estudiar, distintas formas de devolver el resultado etc. . . Al final de este punto ya éramos capaces de obtener un gran conjunto de relaciones en distintos niveles del estudio y un formato que las organizaba y las clasificaba.



## Estado de la Cuestión

Actualmente Internet aloja una cantidad ingente de información de todo tipo. A pesar de los beneficios evidentes que supone tener tanta información subida a la web, este hecho también trae consigo problemas debido a dificultades semánticas, un más que elevado número de fuentes de información y el propio tamaño de los datos. Como consecuencia de esto, para poder hacer consultas a información y navegar de un contenido a otro que esté conectado es necesario tener un sistema de organización para toda esa cantidad de datos.

A continuación exponemos tecnologías cuyo objetivo es acceder a datos con un contexto y a facilitar el proceso de búsqueda al proveer información verdaderamente relevante para los usuarios.

### 2.1. Conceptos sobre el ámbito

La llamada **Web Semántica** es una extensión de la World Wide Web propuesta por Tim Berners-Lee [2], cuyo objetivo es proveer a los datos estructura y significado. Con esto se consigue que la información de la web sea más fácilmente comprensible para las máquinas (o agentes de software). De esta forma se desea lograr que los agentes no solo analicen gramaticalmente, sino que comprendan la gran cantidad de información contenida en la web. Gracias a este entendimiento, los agentes podrán integrar datos de diversas fuentes, inferir hechos ocultos y responder a consultas complejas fácilmente. Finalmente lo que se ha creado es un sistema que permite navegar por la información mediante enlaces o hipervínculos, navegando así entre datos conectados [8].

Para poder hacer realidad esta Web Semántica es necesario que la información de la web sea accesible en un formato estandarizado, accesible y manejable por las herramientas de la Web Semántica. Además, no basta con tener acceso a los datos sino también a la relación entre la información, lo cual marca la diferencia entre la Web Semántica y una simple colección de datasets. Esta colección de datos interrelacionados es lo que llamamos **Linked Data** (o datos enlazados) y será la base de nuestro trabajo en el dominio de los temas musicales.

Hay dos tecnologías que sirven como modelo a la hora de configurar y organizar toda esta información. La primera es el modelo XML “Standard Generalised Mark-up Language-

ge”. Este sistema se basa en la utilización de etiquetas para la descripción y organización de los datos. Un documento XML es capaz de marcar y dotar de significado diferentes partes de un texto que se necesiten nivelar o etiquetar. Se utilizar tanto para representar información en una página HTML hasta organizar registros de una base de datos.

El segundo sistema estructural y actualmente el que nos interesa para este proyecto es el **Esquema RDF** (Resource Description Framework), que es un modelo de datos basado en declaraciones sobre recursos web mediante expresiones sujeto-predicado-objeto. Dichas expresiones se llaman “tripletas”, donde el sujeto representa al recurso, el objeto representa el valor del recurso y el predicado supone los rasgos o aspectos del recurso que relacionan sujeto y objeto [8]. Un ejemplo a grandes rasgos podría ser el siguiente:

```
:Juan es :Persona  
:Juan hijoDe :María
```

Con este simple ejemplo ya hemos representado el hecho de que existe algo llamado Juan, que es una persona y además es hijo de María. Aquí hemos juntado dos conjuntos de tuplas o tripletas relacionadas entre ellas de una forma que podemos representar mediante un grafo.

Es necesario señalar que este es un ejemplo muy básico y sencillo. En la web real, existen millones de tripletas relacionadas entre sí por lo que en nuestro ejemplo tanto Juan como María tendrían un número muy alto de tripletas más que representan toda la información que se tiene sobre ellos en la web.

A la hora de llevar esta explicación a un nivel más técnico y realista, estas expresiones no se formulan con sus nombres en lenguaje natural que hemos usado para el ejemplo. Estos tres argumentos que conforman la unidad de tripleta, se representan mediante un Identificador de Recursos: una URI (Uniform Resource Identifier) [8, 1].

Una URI (Uniform Resource Identifier) es una cadena de caracteres que puede identificar una entidad o recurso por su nombre o bien por su ubicación, la cual muestra dónde podemos acceder a él. Siguiendo esta división, una URI puede comprender el URL (Uniform Resource Locator) y el URN (Uniform Resource Name). La URN identifica la entidad por su nombre, lo cual no nos proporciona su ubicación y no asegura que esta entidad esté disponible. Sin embargo, la URL nos proporciona la localización directa de la entidad y esta es la principal razón de que sea mucho más usada en la web [3, 7, 8].

Volviendo a lo que respecta al modelo RDF, hemos determinado el hecho de que si empleamos este lenguaje seremos capaces de relacionar un sujeto y un objeto mediante un predicado, de forma que obtendremos un grafo similar al siguiente:

A simple vista para una persona, puede resultar una nomenclatura poco amigable de representar ya que las URIs pueden llegar a ser mucho más engorrosas y complejas. Más adelante explicaremos como hemos resuelto este problema en nuestro proyecto para que cualquiera que haga uso de nuestra futura interfaz pueda reconocer todos los objetos y sobre todo para darnos mucha más comodidad a la hora de trabajar con ellos.

Podríamos decir que estamos estableciendo una relación entre dos objetos unidos me-



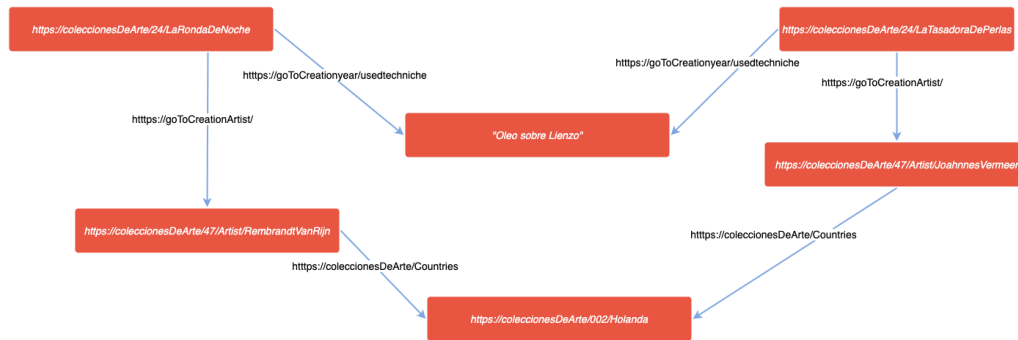


Figura 2.1: Ejemplo de grafo siguiendo el modelo RDF

dante una propiedad. Esta propiedad es una “explicación” que nos sirve para relacionar objetos. En nuestro proyecto, estos objetos son canciones.

## 2.2. SPARQL

Finalmente, para poder empezar a trabajar con la información hemos usado el lenguaje SPARQL, el cual nos permite consultar los datos enlazados de la web. Este es un lenguaje especializado para buscar y consultar datos RDF. Básicamente facilita el acceso a las URIs para después poder aplicar todo tipo de selección de datos, restricciones, condiciones y límites a las entidades con los esquemas explicados anteriormente. La estructura de una consulta SPARQL suele ser la siguiente:

```

PREFIX EX: Uri de una web
SELECT * variables que se desean conseguir
WHERE
{
  Operaciones con tripletas
}
OFFSET X intervalo de desplazamiento
LIMIT X limite de los datos obtenidos
  
```

La cadena PREFIX hace referencia a la URI o URIs donde se encuentran localizados las entidades a las que hacen referencia las tripletas. Su objetivo es no tener que escribir la URI entera, la cual es una cadena de texto poco amigable para un usuario, cada vez que lo referenciáramos en una relación de las tripleta dentro de la cláusula WHERE.

A la hora de hacer una consulta compleja, es posible que lleguemos a un código que referencie muchas URIs y entidades de forma que no sea un lenguaje de uso fácil. Es por esto por lo que pudimos encontrar variedad mediante la librería que nos dispone Wikidata que simplifica algo más la nomenclatura y los caracteres de este lenguaje.

## 2.3. WikiData

Wikidata es una base de datos libre, colaborativa, multilingüe y secundaria, que reco-pila datos estructurados para dar soporte a Wikipedia, Wikimedia Commons, así como a

otras wikis del movimiento Wikimedia y a cualquier persona en el mundo [4]. El proyecto comenzó en 2012 liderado por wikimedia Alemania. Gracias a Wikidata, tenemos una gran cantidad de información relevante acerca de toda nuestra cultura reunida en un mismo sitio. La usaremos para consultar e investigar la información relacionada con nuestro dataset (o conjunto de datos), esencialmente datos acerca de artistas y sus temas musicales. Tiene numerosos servicios, uno de los que probablemente hayamos usado y no nos hemos dado cuenta, es el de servir información para rellenar las fichas de los artículos de Wikipedia.

Wikidata está estructurada de tal manera que resulta sencillo acceder a su información utilizando el lenguaje de consultas SPARQL. Cada objeto tiene ciertas propiedades a las que podemos acceder seleccionando el identificador correcto de la propiedad.

Una de las ventajas de Wikidata es que nos va a eliminar toda la nomenclatura de URIs propias de SPARQL. En estas consultas, las entidades serán referenciadas con los caracteres `wd` y las propiedades con los caracteres `wdt`. Un ejemplo de una consulta sencilla podría ser:

-Obtén todos los Artistas cuyo género musical sea Rock:

```
SELECT ?singer ?singerLabel ?genre ?genreLabel
WHERE
{
  ?singer wdt:P31 wd:Q215380;
  wdt:P136 wd:Q7749;
  SERVICE wikibase:label { bd:serviceParam wikibase:language "en"; . }
}
```

En esta consulta estamos accediendo a todos los objetos que contengan las propiedades (`wdt`) `P31` (Tipo Instancia) y `P136` (Género) con el valor (`wd`) que nosotros estamos seleccionando, `Q215380` y `Q7749`, forzando así a que las dos propiedades sean Grupo Musical y Rock and Roll respectivamente.

SPARQL es un lenguaje muy potente que puede abarcar gran cantidad de datos en función de la web (se pueden crear consultas mucho más complejas para obtener datos más específicos).

# Capítulo 3

## Explicaciones

El objetivo de nuestro trabajo consiste en explicar las relaciones entre dos canciones dadas por un recomendador de música que trabaja con un dataset concreto. De esta manera, llamaremos **explicación** a cada factor común que compartan ambas canciones, siendo principalmente propiedades que poseen las propias canciones o los valores de otras propiedades previas. A lo largo de este capítulo concretaremos todas las explicaciones que vamos a estudiar y el sistema que une todas ellas para poder relacionar dos canciones en su totalidad.

Las relaciones que recogemos en cualquier caso de uso forman un grafo siguiendo el sistema RDF. Nosotros hemos decidido además de seguir ese formato, dotarlas de un nivel que escala en función el estudio se aleje del objeto canción inicial. Al expresar alejamiento, nos referimos a que como en el contexto del formato RDF y Linked Data, la creación de relaciones se establece navegando por distintos objetos relacionados con el inicial secuencialmente. El motivo de los niveles viene dado por: //

El primero es debido a la cercanía de niveles. Cuanto menor sea el nivel, significará que está mas próximo al objeto canción inicial y por ello tendrá más peso a la hora de relacionarlas

El segundo es porque a la hora de representar gráficamente todas las relaciones, queremos dividir las por objetos de estudio nivelada y ordenadamente.

En una primera fase, generaremos explicaciones básicas para relacionar directamente las dos canciones u objetos principales, por ejemplo: género, artista, álbum, etc. Asignaremos una complejidad de  $k=1$  a las explicaciones directas. Estas explicaciones son una relación directa entre dos canciones relacionadas por una propiedad, es decir, solo tenemos en cuenta propiedades ligadas a cada objeto en un primer nivel.

Una vez obtenemos las relaciones básicas, es necesario seguir avanzando en el estudio, ya que dos canciones que a priori no son muy similares musicalmente, no compartirán casi ninguna de estas relaciones directas. Es por esto por lo que indagamos más en la información que podemos obtener a partir de las relaciones que hemos sacado en el paso anterior. Aquí aparecen las relaciones indirectas, aquellas que surgen del estudio de otras obtenidas en niveles anteriores, siempre que coincidan en ambas canciones. La idea es poder representar toda la información compartida, de forma que se pueda representar con un grafo. Estas explicaciones pueden tener un nivel de complejidad diferente ( $k= 2, 3, 4...$ ) dependiendo

de cuántos niveles se hayan estudiado. La idea principal es ejecutar un estudio de ambas canciones obteniendo varios niveles de cada una de ellas, para finalmente unir las enlazando únicamente las que coincidan.

Hemos recopilado a lo largo de investigación y consultas un conjunto de posibles relaciones a obtener, que suman un total de 24 explicaciones. Es importante añadir que la mayoría de ellas pueden presentarse en distintos niveles. Para explicar este caso más fácilmente lo representamos con el ejemplo de la Figura 3.1.

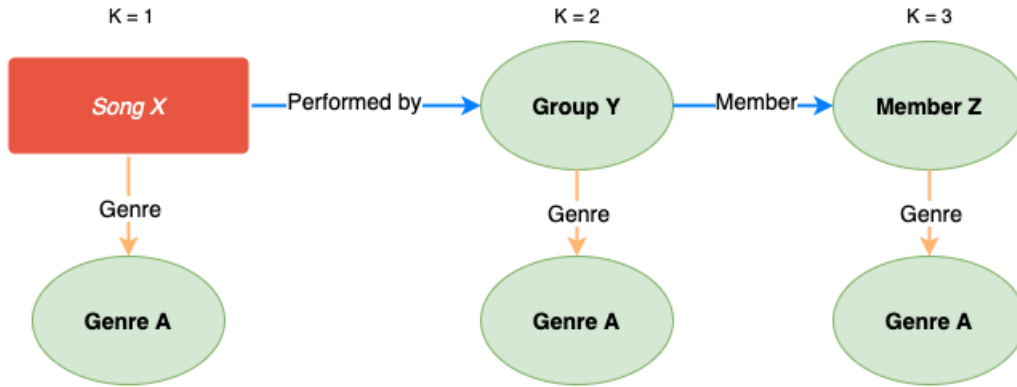


Figura 3.1: Ejemplo de misma relación en distintos niveles

Para nuestro caso, en el cual tratamos con dos objetos iniciales que representan a dos canciones, hemos seleccionado una serie de propiedades a investigar para obtener los distintos niveles. El primer nivel es el más intuitivo: obtener relaciones directamente de ambas canciones. Entre esas relaciones se encontraría la relación “Interpretado por”, la cual nos proporciona el artista o grupo que interpreta la canción. Este artista es el que vamos a usar como objeto de estudio del nivel  $k = 2$ , obteniendo así otro conjunto de relaciones del artista y sus respectivos valores. También obtendremos el género de la canción, que usaremos para generar el nivel  $k = 3$  mediante las propiedades que obtengamos del género. Por último, como nivel final hemos seleccionado investigar las propiedades de los miembros que conforman la banda de música en caso de que el intérprete de la canción esté formado por varios artistas, y denominamos a este último nivel  $k = 4$ .

Queremos señalar que estos niveles podrían alargarse más a medida que seguimos investigando nuevas propiedades y generando un grafo más completo. Hemos decidido poner un límite en este punto debido a que, a medida que vamos avanzando en el estudio de los niveles de las propiedades, las explicaciones son menos significativas debido a que están más alejadas del primer nivel, que es el que está relacionado con la canción en sí.

En esta sección vamos a recopilar las principales propiedades de la lista total y como relacionarían dos canciones objeto iniciales. Algunas de ellas podrán aparecer en distintos niveles mientras que otras serán propias de un solo nivel:

### 3.1. Explicaciones de la canción

Aquí se encuentran las principales propiedades propias del objeto canción que no pueden tener el resto de niveles:

#### Artista

El artista es una de las explicaciones más obvias pero también es una de las más importantes. Esta explicación hace referencia a cuando dos temas son interpretados por el mismo artista, por lo que tienen una clara relación directa ya que suele existir similitud entre las canciones de un artista. Además, a partir del artista podemos obtener otras relaciones más complejas en función de los datos de este mismo.

Como ejemplo podemos tomar los temas *One More Time* y *Get Lucky*. Ambos son interpretados por el dúo musical **Daft Punk**, así que podemos explicar su relación gracias a este dato.

Para esta explicación utilizamos la propiedad “performer” (intérprete) de Wikidata. Siguiendo el modelo RDF, el sujeto es la canción (*One More Time*, por ejemplo), el predicado es la propiedad intérprete y el objeto es el artista (**Daft Punk**).



Figura 3.2: Ejemplo de explicación por artista

#### Álbum

Una explicación muy potente será que ambas canciones pertenezcan al mismo álbum. A menudo esta explicación aparecerá acompañada de la explicación del artista y, en cualquier caso, la relación que existe entre dos temas del mismo álbum suele ser más estrecha debido a que poseen más puntos en común, como puede ser el género, la fecha o la temática.

Tomemos como ejemplo *Smells Like Teen Spirit* y *Come as You Are*. Estas dos canciones son muy cercanas porque tienen varios puntos en común, pero una de las explicaciones que podemos ofrecer es que ambas pertenecen al álbum *Nevermind*, de **Nirvana**. *About a Girl* es otro tema que se podría recomendar a raíz de *Smells Like Teen Spirit*, pero es una peor elección que *Come as You Are* porque pertenece a un álbum diferente.

Volvemos a utilizar Wikidata para obtener esta explicación, concretamente la propiedad “part of” (parte de). Esta propiedad se utiliza para varias cosas, entre ellas indicar los álbumes a los que pertenecen las canciones. Así obtenemos que *Smells Like Teen Spirit* es “parte de” *Nevermind*.



Figura 3.3: Ejemplo de explicación por álbum

### Publication Date(Decade)

Creemos que hay una mayor probabilidad de que exista una relación entre dos canciones que pertenezcan a la misma década. Esto se debe a que a lo largo del tiempo ha habido periodos marcados por uno o varios géneros musicales. Esto también ayuda a estudiar cómo estos distintos géneros están relacionados entre sí, lo cual es otro punto importante a tener en cuenta ya que hay géneros íntimamente relacionados entre sí: techno y house, heavy metal y thrash metal, etc.

Gracias a esta explicación, podemos relacionar dos canciones que a priori son muy distintas, como es el caso de *September* de **Earth, Wind & Fire** y *Bohemian Rhapsody* de **Queen**. Estos temas no comparten algo tan básico como el artista o el género, pero ambos fueron publicados en los años 70 y por ello pueden resultar interesantes para un usuario que busque escuchar los ritmos de esa época.

Para obtener esta explicación, emplearemos la propiedad “publication date” (fecha de publicación) de las canciones en Wikidata y comprobaremos si las dos fechas se sitúan dentro de la misma década.



Figura 3.4: Ejemplo de explicación por década

### Singles

Existe también una cierta relación entre aquellos temas que sean singles o sencillos, así que consideramos esto como una explicación más. El razonamiento para esta decisión es que los singles son canciones que se publican de forma independiente por razones promocionales, por lo que suelen convertirse en los temas más populares y representativos del trabajo del artista. Por ello, pueden poseer más valor para el recomendador que otras canciones porque los singles tienen más probabilidades de coincidir con los gustos del usuario.

El tema *Bad Guy* de **Billie Eilish** es un single, así que podemos decir que tiene cierta relación con *Shallow* de **Lady Gaga** y **Bradley Cooper**, que también es un single.

Para esta explicación emplearemos la propiedad “instance of” (instancia de) en Wikidata y su valor “single”. De esta forma comprobaremos que tanto *Bad Guy* como *Shallow* son “instancia de” “single”.



Figura 3.5: Ejemplo de explicación por single

## 3.2. Explicaciones compartidas por Artista y Canción

En esta sección exponemos propiedades que pueden ser establecidas tanto en el nivel de estudio de la canción como también en el artista.

## Premios

La siguiente explicación son los premios recibidos. Existe una variedad de premios compartidos por diferentes canciones. Algunos de estos premios son más específicos que otros, pero en cualquier caso pueden resultar una relación útil para nuestras explicaciones ya que son un reflejo de la repercusión de las canciones. El mismo caso se da para los artistas, aquellos que suelen optar al mismo premio, tienen más posibilidades de tener un estilo muy similar y por ende se puede establecer una relación de cercanía.

En esta sección hemos recogido dos propiedades: “award received” (premio recibido) y “nominated for” (nominado a). Estas categorías hacen referencia a los premios que ha recibido los artistas o canciones y la segunda a los premios a los que han sido nominados. Normalmente los premios se reparten según distintas categorías en función al estilo de música, pero también hay otros que nos aportan otro tipo de información al estudio como Grammy al Mejor Videoclip, Grammy Award a la Mejor Canción Escrita, Grammy Award a la Mejor Interpretación Rap/Sung etc...

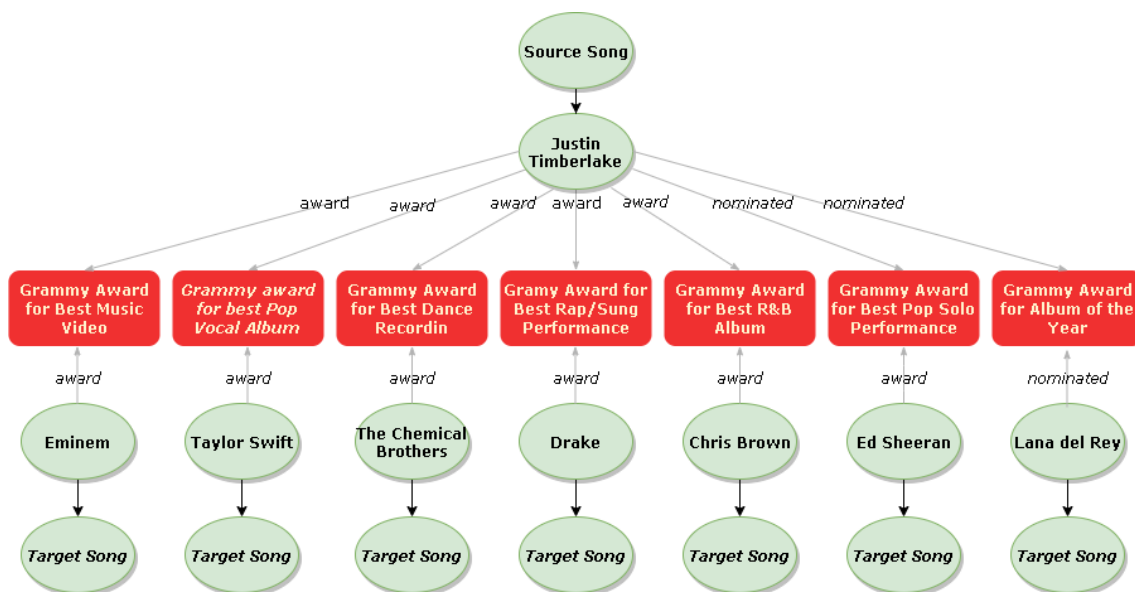


Figura 3.6: Ejemplo Relaciones que pueden tener artistas por premios

Basándonos en el nivel de canción tenemos como ejemplo *Single Ladies (Put a Ring on It)* de **Beyoncé** y *Rolling in the Deep* de **Adele**, ya que ambos temas han recibido el Premio Grammy a la canción del año. Así explicaríamos la relación entre *Single Ladies (Put a Ring on It)* de **Beyoncé** y *Rolling in the Deep* de **Adele**, ya que ambos temas han recibido el Premio Grammy a la canción del año.

Usaremos la propiedad “award received” (premio recibido) encontrada en Wikidata. De esta forma, *Rolling in the Deep* sería el sujeto, “award received” sería el predicado y *Grammy Award for Song of the Year* sería el objeto.




Figura 3.7: Ejemplo de explicación por premio

## Género

La explicación Género es una de las más representativas ya que las personas se guían por el género que prefieren para escuchar canciones similares, aunque en ocasiones no deba ser así. Un usuario que sea fan del jazz querrá escuchar canciones de ese mismo género o géneros similares porque todas las canciones de un mismo género comparten una serie de puntos en común como la elección de los instrumentos, temáticas similares en sus letras o patrones de composición.

Gracias al género, podemos explicar la relación entre canciones como *Master of Puppets* de **Metallica** e *Indians* de **Anthrax**, que pertenecen al **thrash metal**.

Para esta relación utilizamos la propiedad “genre” (género) de Wikidata. Así tenemos que la canción *Master of Puppets* pertenece al género **thrash metal**.



Figura 3.8: Ejemplo de explicación por género

En este caso podríamos crear la misma relación con los artistas, debido a que ambos artistas de las dos canciones previas también cuentan con un registro de thrash metal (entre otros géneros) en su propiedad de género.

## Idioma

La explicación Idioma denota, como su nombre sugiere, que ambas canciones están en el mismo idioma o lenguaje. Existen numerosos ejemplos de temas musicales que están escritos en un idioma que no se corresponde con la lengua materna del artista que los publica, o sencillamente están escritas en un idioma que se habla en varias partes del mundo distintas, como el inglés o el español. En ciertos casos el compartir idioma es un indicativo de otras relaciones adicionales, como puede ser el caso de canciones que pertenecen a un folclore regional determinado. En cualquier caso el compartir lenguaje ya es una relación directa en sí misma.

Como ejemplo podemos tomar el tema *Like a Virgin* de **Madonna** y *Rocket Man* de **Elton John**, los cuales están escritos en inglés.

Para esta explicación emplearemos la propiedad “language of work or name” (idioma de la obra o del nombre) de Wikidata. Así tenemos que la canción *Like a Virgin* tiene idioma “inglés”.

El mismo caso podría servir de ejemplo para relacionar ambos artistas con la misma propiedad de idioma significando que ambas canciones son interpretadas en ese idioma.





Figura 3.9: Ejemplo de explicación por idioma

### 3.3. Explicaciones compartidas del Artista y los Miembros

En esta sección solo aparecen las principales propiedades que por naturaleza son exclusivas de un artista, ya sea un artista en solitario o un miembro del grupo.

#### Record Label

Record Label (compañía discográfica) hace referencia a la compañía por la que ha firmado el artista para publicar un tema concreto. Hemos podido observar que una misma compañía puede firmar a artistas que a veces no tienen relación ninguna en cuanto al estilo musical, pero hay otras causas que sí los pueden relacionar indirectamente como la tendencia del momento, el target del público que generan, etc. También se puede dar el caso en el que un miembro del grupo firme o haya firmado con una compañía individual, ya sea por conceptos relacionados con marcas, representantes o contratos.

Para ilustrarlo con un ejemplo, tanto la canción *Born in the U.S.A.* de **Bruce Springsteen** como la canción *Ashes* de **Céline Dion** fueron publicadas por el sello discográfico **Columbia Records**.

Podemos alcanzar esta explicación gracias a la propiedad “record label” (sello discográfico) de Wikidata. *Born in the U.S.A.* tiene un “record label” cuyo nombre (o valor) es **Columbia Records**.



Figura 3.10: Ejemplo de explicación por compañía discográfica

#### location of formation

La propiedad “location of formation” (lugar de formación) que hace referencia a la localidad de formación del grupo o artista, puede parecer muy similar a la explicación “country of origin” pero esta ejerce una selección más precisa pues nos da un núcleo de población más pequeño. Un ejemplo de ello podría ser dos míticas bandas de la ciudad de Boston: Aerosmith y Boston. Creemos que la unión de la ciudad natal con la música puede hacer a un usuario el escuchar grupos de su misma ciudad o estado. En cuanto a la relación referente a un miembro del grupo, se trataría del lugar donde ese miembro se formó músico ya sea como artista en solitario o en su grupo original.




Figura 3.11: Ejemplo de explicación por Location of Formation

### 3.4. Explicaciones compartidas en el Artista, Miembro, Género y Canción

Estas explicaciones son compartidas en los cuatro niveles y resultan de gran interés porque nos permitirán enlazar los cuatro mismos en el caso en el que coincidan en el objeto con las relaciones de la canción opuesta.

#### Country of origin

Esta explicación puede ser especialmente útil para países relativamente pequeños donde la música nacional presenta unos patrones claros. Además, a lo largo de la historia en un país se genera una tendencia o nuevo género musical el cual es propio de ese país en el que se forma un artista y esto nos daría una relación muy específica que definitivamente acertaría por completo en la relación 1 a 1 de dos canciones.

En países que son significativamente grandes o con una población muy alta, perdería algo de especificidad, pero aún así hay más posibilidades que dos artistas del mismo país sean escuchados por un mismo usuario.

La canción *Fire* de la banda **BTS** y *Kill This Love* de **Blackpink** guardan cierta similitud porque ambos grupos son originarios de **Corea del Sur**.

Para comprobarlo, obtendremos la propiedad “country of origin” (país de origen) del artista que previamente ya hemos almacenado al estudiar las relaciones directas en el caso de las bandas o la propiedad “country of citizenship” (país de nacionalidad) en el caso de los artistas en solitario. *Fire* tiene el “performer” **BTS**, cuyo “country of origin” es Corea del Sur.




Figura 3.12: Ejemplo de explicación por país de origen

También podemos recoger la información del país donde se formó ese género. Con esta propiedad queremos poder recoger movimientos artísticos que surgieron en el mismo país. Los géneros que fueron formados en un determinado país están mucho más arraigados a este a pesar de que se hayan extendido por todo el mundo. Es por esto que si queremos relacionar una artista que cualquier parte del mundo, que tiene un estilo Techno, será más propenso a estar relacionado con artistas o canciones Holandesas, cuna del este estilo musical.

En el caso de que la propiedad se entableciese en la canción, significaría que ambas canciones han sido lanzadas originariamente en el mismo país.

### Influenced by

La **influencia de los artistas** es otra explicación importante. A menudo el trabajo de un artista se ve influenciado por otros artistas de formas que no siempre están ligadas a un género musical concreto, así que podemos encontrar una relación entre dos canciones examinando estas influencias.

Tomando como ejemplo las canciones *Billie Jean* de **Michael Jackson** y *Paint It Black* de **The Rolling Stones**, podemos establecer una relación entre ellas al ver que ambos artistas fueron influenciados por la banda **The Beatles**.

Obtenemos esta explicación gracias a la propiedad “influenced by” (influenciado por) de Wikidata, además de la propiedad “performer” para relacionar el tema con su artista. Así averiguamos que *Billie Jean* tiene de “intérprete” a **Michael Jackson**, quien fue “influenciado por” **The Beatles**.



Figura 3.13: Ejemplo de explicación por influencia

Al igual que con el artista, los géneros también son influenciados por otros los cuales ha servido para el desarrollo de nuevos estilos a lo largo de la historia. Gracias a la evolución del Rock hay otros géneros que han marcado tendencia como el Rock and Roll, el Heavy Metal, Hard Rock, Garage Rock etc...

## 3.5. Propiedades propias del artista o grupo

Aquí se exponen las principales relaciones que solo pueden ser propias del artista o grupo.

### Integrantes

Los **integrantes** son cada uno de los miembros que conforman un grupo. En caso de ser un único artista, esta propiedad es irrelevante ya que haríamos referencia a la propiedad directa de artista. Esta propiedad resulta útil en casos en los que miembros de la banda han cambiado de grupo a lo largo de su carrera musical. Esto nos da acceso a otros grupos que por valores o gustos musicales del artista nos hacen pensar que pueden ser muy parecidos.

Si tomamos los temas *Lithium* de **Nirvana** y *The Pretender* de **Foo Fighters** podemos observar que existe una relación entre ellos porque el músico **Dave Grohl** ha formado parte de ambas bandas.

Para comprobarlo usaremos la propiedad de Wikidata “performer” y después comprobaremos la propiedad “has part” (compuesto de) para ver todos los miembros de la banda y buscar coincidencias. De este modo, podemos ver que *The Pretender* tiene un “performer” que es **Foo Fighters**, y a su vez **Foo Fighters** “has part” **Dave Grohl**.




Figura 3.14: Ejemplo de explicación por integrantes

### Tipo de voz

Siguiendo con el estudio de los artistas, el **tipo de voz** de los vocalistas es una buena explicación para relacionar dos canciones. El tipo de voz influye en el sonido general del tema y puede ser especialmente determinante en ciertos géneros musicales. Por limitaciones técnicas, solo aplicaremos esta explicación con artistas en solitario.

La voz de un artista puede encajar en más de un tipo, como veremos en el siguiente ejemplo, aunque en esta explicación buscamos que coincidan en al menos un tipo. La cantante **Lady Gaga** se asemeja a **Amy Winehouse** por su tipo de voz, ya que ambas son *mezzo-soprano* y *contralto*. Así podemos explicar la relación entre dos canciones de estas artistas como *Poker Face* y *Rehab*.

Para esta explicación resulta útil la propiedad “voice type” (tipo de voz) en Wikidata. Partiendo de *Poker Face*, utilizamos la propiedad “performer” para llegar a **Lady Gaga** y finalmente usamos su “voice type” para obtener *mezzo-soprano*.

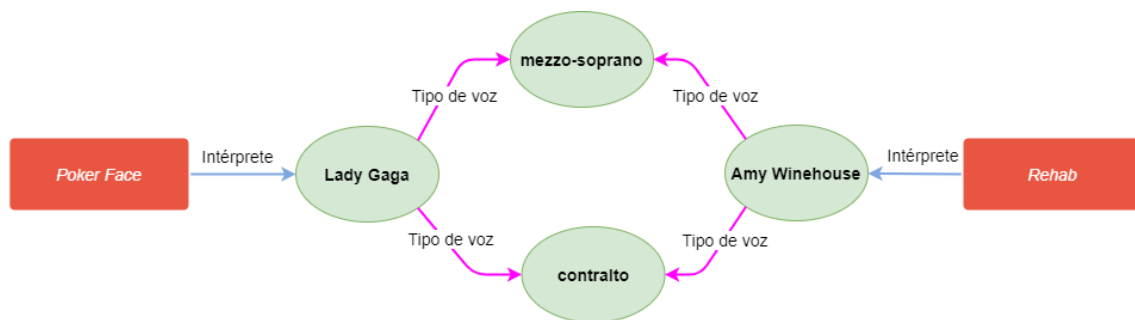


Figura 3.15: Ejemplo de explicación por tipo de voz

### Work period Start

Con esta propiedad intentamos tener en cuenta la historia de los o su cronograma. Hay Grupos que comenzaron su etapa musical conjuntamente a lo largo del tiempo. Un ejemplo de este caso se dio en curiosamente el tecnopop que tanto caracterizó a los años 80, pues convivió a veces con el soul y el estilo afroamericano doo-wop, de Billy Joel.

## 3.6. Explicaciones basadas en el género

Estas propiedades vienen ligadas directamente al género de la canción. Es una de las propiedades más detalladas en Wikidata y por lo tanto una de de las que más información

nos pueden proporcionar. Hay muchos géneros y subgéneros documentados, lo que nos facilita la obtención y clasificación de estos

### 3.6.1. Subgenre

Cabe destacar la diferencia entre las propiedades Influenced by y Subgenre, mientras que la primera solo indica que ese estilo musical ha marcado una cierta influencia tomando algunos aspectos, la segunda señala que es un Subgénero, una tendencia muy parecida y que toma como base ese estilo musical.




Figura 3.16: Ejemplo de explicación por Subgénero



## Diseño de la interfaz de explicaciones

El objetivo de nuestro proyecto, como ya hemos expresado anteriormente en este documento, consiste en proporcionar explicaciones que justifiquen la relación existente entre dos canciones proporcionadas por un recomendador de música. Una vez realizado el estudio de las canciones y las distintas explicaciones posibles, es necesario mostrar el resultado de nuestro estudio de una forma gráfica, comprensible para un usuario humano.

Los datos que manejamos en nuestro estudio consisten en objetos y las relaciones que existen entre ellos, pues siguen el modelo de datos RDF. Necesitamos representar todos los caminos que se forman entre las dos canciones iniciales, mostrando las conexiones existentes entre los objetos intermedios. Por estos motivos hemos decidido llevar a cabo la visualización mediante un grafo porque consideramos que se adecuaba mejor a nuestras necesidades.

Es importante que la interfaz sea fácil de entender y usar, así que siempre trataremos de mantenerla lo más sencilla posible. La base de nuestro diseño es el grafo de explicaciones ya mencionado, pues es el elemento más importante debido a la gran cantidad de información que aporta y, por lo tanto, es también la parte central de la interfaz alrededor de la cual se posicionarán el resto de elementos.

### 4.1. Diseño del grafo

En la Figura 4.1 se puede observar la primera iteración de nuestro diseño. En ella se ve un ejemplo de grafo donde los nodos son los distintos sujetos y objetos (según el modelo RDF), mientras que las aristas representan los predicados que relacionan a esos nodos.

Los nodos posicionados a ambos extremos son las canciones sobre las que estamos realizando el estudio, diferenciados por el color rojo. A partir de ellas parten todas las explicaciones. En el centro se puede ver también un nodo coloreado de un rojo más suave, este representa al objeto de una explicación directa (en este caso la explicación “Idioma”).

Los nodos coloreados de color naranja representan los artistas de ambas canciones y las relaciones que existen entre ellos, de la misma forma que en el anterior caso con las canciones y las explicaciones directas. Estas explicaciones obtenidas por el estudio de los artistas son indirectas, ya que requieren un estudio más profundo para relacionar las can-




Figura 4.1: Primer diseño de la interfaz web

ciones originales.

Por último tenemos nodos morados que representan a los miembros o integrantes de los artistas, pues en este caso dichos artistas son bandas formadas por varias personas. Su funcionamiento es el mismo que el descrito en el párrafo anterior, con la salvedad de que estos miembros se obtienen del artista y, por lo tanto, sus explicaciones presentan un nivel extra de profundidad.

En esta versión del diseño también se propone una funcionalidad que permite visualizar datos adicionales. Haciendo click en los nodos sobre los que se hacen los estudios (canciones y artistas), se despliega una sección inferior en la que se muestran todos los datos obtenidos en el estudio del elemento concreto, aparezcan en el grafo o no. Así podemos ver todos los sellos discográficos con los que trabajaron **The Rolling Stones** aunque solo **Polydor Records** los relacione con **The Beatles**.

Esta función no es integral para el objetivo de nuestro proyecto, tan solo es un complemento que ofrece opciones al usuario, pero consideramos que puede ser un añadido interesante.



## 4.2. Diseño básico de la interfaz

Pasaremos ahora a explicar el resto de la interfaz con la ayuda de la Figura 4.2. En esta iteración, el diseño del grafo se mantiene intacto en su mayor parte. La novedad a destacar es que se pueden ver las explicaciones indirectas obtenidas por el estudio de los géneros de la canción, representados por nodos de color verde.

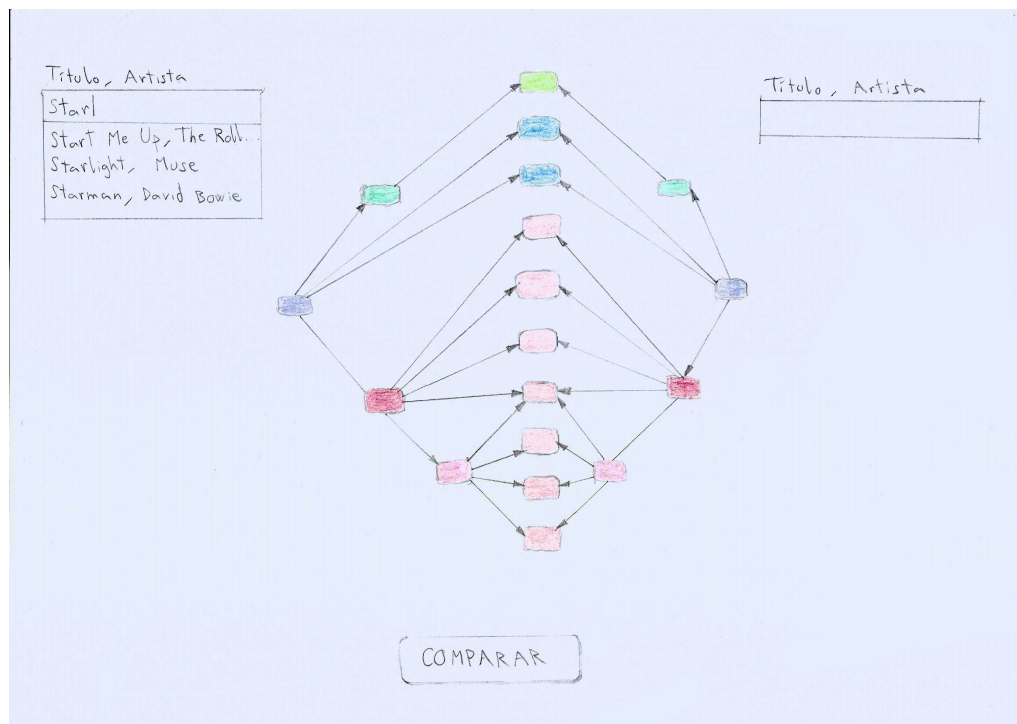


Figura 4.2: Segundo diseño de la interfaz web

El resto de la interfaz consiste en los elementos con los que interactuará el usuario antes de generar el grafo de explicaciones. A ambos lados de la pantalla se sitúan los campos a rellenar con los datos básicos de las canciones. Para identificar la canción deseada es necesario escribir en ellos el título de la canción y el nombre de su artista, separados por una coma. En realidad este campo de entrada es un buscador que mostrará en un desplegable la lista de canciones que coinciden con el texto introducido y el usuario deberá seleccionar la que está buscando. Si intenta comparar una canción no contemplada por el sistema, aparecerá un mensaje de error.

La decisión de limitar las posibles entradas ha sido tomada por motivos prácticos. En Wikidata hay una cantidad ingente de temas musicales registrados, sin embargo los datos de cada canción concreta no siempre son tan completos como cabría esperar. A menudo falta información o la que hay no aparece siguiendo los mismos estándares que el resto, especialmente cuando se trata de canciones menos populares. Por ello hemos elaborado una lista de canciones que poseen información útil en Wikidata y que podemos tratar en nuestra aplicación sin problemas.

Por último, en la parte inferior de la pantalla hay un botón para "COMPARAR". Una vez rellenados los campos de las dos canciones con opciones válidas, el usuario deberá pul-

sar este botón para que se dibuje el grafo de explicaciones. La primera vez que se use la aplicación no aparecerá ningún grafo en el centro de la interfaz, pero en las comparaciones siguientes el grafo previo no se borrará hasta pulsar de nuevo este botón para dibujar un grafo nuevo.

4.3. Diseño avanzado




Figura 4.3: Tercer diseño de la interfaz web

Partiendo de la base establecida en los apartados anteriores, hicimos un diseño más completo de la interfaz para nuestra aplicación. Aquí se puede ver el regreso de la sección inferior con datos adicionales de los artistas y las canciones, esta vez en forma de tabla para que sea más legible para el usuario.

También por motivos de visibilidad y comprensibilidad se ha desplazado el botón “COMPARAR” a la parte superior de la pantalla, además de mostrar una lista con todas las canciones disponibles bajo los campos de entrada. Esta decisión se ha tomado para tratar de evitar que el usuario se sienta perdido por la falta de opciones visibles al abrir la aplicación por primera vez. Cabe destacar que esta lista se sigue filtrando en función de la entrada que esté escribiendo el usuario, mostrando así cuáles son sus opciones en todo momento.

En esta iteración se hacen algunos cambios al grafo de explicaciones. Para empezar, el nombre de las explicaciones (el predicado según RDF) se traslada a las aristas. También se han colapsado los nodos correspondientes a los premios recibidos por los artistas para eliminar aristas y nodos innecesarios.

De la misma forma se colapsan los nodos de los miembros de los artistas, reduciéndolos a un solo nodo por artista. Para expresar cuántos integrantes se ven involucrados en cada explicación, el grosor de la arista que los une varía en función del número de miembros que participan en esa explicación concreta. Además, al colocar el ratón sobre esas aristas aparece una etiqueta donde figuran los nombres de esos miembros. Este cambio se propuso para reducir el número de nodos y aristas, pues en ciertos casos podía ser abrumador a la vista.

Por último, cabe destacar las pestañas que se ven justo encima del marco para el grafo. Para tratar de mejorar la legibilidad lo máximo posible decidimos hacer dos grafos diferentes, siendo el que vemos en la Figura 4.3 el de “explicaciones cercanas”. Este grafo muestra solamente las explicaciones existentes entre elementos del mismo “nivel de estudio”. Esto quiere decir que, por ejemplo, el género de una canción solo podrá relacionarse con un género de la otra canción, pues corresponden al mismo estudio. Por el contrario, no se verán relaciones existentes entre ese género y otro elemento, como una canción, artista o miembro.




Figura 4.4: Grafo de explicaciones lejanas

En la Figura 4.4 se ve el llamado “grafo de explicaciones lejanas”, con el que se ve mejor la diferencia. Al contrario del “grafo de explicaciones cercanas”, aquí solo se muestran las explicaciones existentes entre elementos que pertenecen a estudios diferentes. De esta forma, en este grafo se ve la relación entre el artista **The Rolling Stones**, autor de la primera canción, y el género **pop rock** obtenido de la segunda canción.

El usuario podrá cambiar de vista libremente para consultar ambos grafos haciendo click en las pestañas anteriormente mencionadas. Todas las funciones explicadas en esta sección aparecen en ambos grafos.

# Capítulo 5

## Implementación

### 5.1. Procesamiento y manejo de la muestra

Partimos de una muestra (o **dataset**) de alrededor de 19 millones de líneas, obtenido a partir de la API de **Last.fm** [5], una plataforma que almacena y proporciona mucho contenido musical. Constaba de los siguientes campos: `<user, timestamp, artist, song>`, los cuales hacen referencia al usuario que ha escuchado la canción, la fecha en la que fue escuchada, el nombre del artista y el título de la canción respectivamente.

El primer paso fue hacer un pequeño estudio del dataset para hacernos una idea de cómo era nuestra muestra y qué podríamos sacar de ella. Se trataba de un dataset con muy pocos campos que no daba información ninguna sobre la canción o el artista, sino que solo proporcionaba un medio para poder obtenerla de una fuente externa. Hicimos una limpieza del dataset, ya que había numerosos valores que eran nulos en determinados campos o no tenían una codificación correcta.

Es en este punto donde comenzamos a pensar cómo queríamos mostrar la información que podíamos ofrecer previa al funcionamiento de la aplicación. Dudábamos entre permitir utilizar cualquier objeto del dataset o restringirlo solo a algunos.

En la librería de Wikidata, por motivos obvios, se debe poner como entrada de cualquier función de búsqueda el código identificador del objeto sobre el que se quiere obtener información. Estos identificadores son fijos y únicos para cada uno de los objetos que están registrados en la página. Con nuestra librería somos capaces de, a partir de un string que represente un título de canción o un artista, género, etc., obtener su respectivo identificador para posteriormente procesar las consultas.

El problema aquí es que para obtener el identificador del objeto, su nombre o título debía ser exacto al que aparecía en Wikidata, pues de cualquier otra forma se lanzaría una excepción. Por ejemplo, intentar obtener el identificador de la canción “Don’t Stop me Now” sería incorrecto, porque en Wikidata figura como “Don’t Stop Me Now”. Debido a esto, es necesario hacer un parseo previo de cualquier String (o cadena de caracteres) que se vaya a utilizar como entrada.

Finalmente decidimos crear una lista preseleccionada y parseada de las canciones más

populares de todo el dataset. Para ello ordenamos las canciones del dataset por popularidad descendente, entendiendo como popularidad la cantidad de veces que aparecían en la muestra. Después elaboramos un script que recorría todas ellas, ejecutaba el parseo y finalmente comprobaba si era posible obtener los datos de Wikidata.

Empezamos con un dataset de las 2500 canciones más populares y fuimos capaces de obtener la información de 1408 canciones con su determinado artista. Cabe señalar que en cada búsqueda de una canción se debe añadir su artista, pues hay varias canciones con el mismo título que no podrían diferenciarse de otro modo.

Nuestra aplicación final funciona con este dataset limitado pero que cuenta con la seguridad de que se pueden obtener datos fiables sin importar la canción que se elija. Además, al haber escogido las canciones con mayor popularidad nos vamos a encontrar con mayor cantidad de datos ya que estas eran las que más documentadas estaban. a diferencia de las que estaban en la parte inferior del dataset, que eran muy poco conocidas y apenas se podían sacar datos valiosos sobre ellas.

## 5.2. Estudio del dataset

Para poder comprender mejor el dataset obtenido con el objetivo de poder ofrecer al usuario una lista limpia, donde sea cual sea la opción que elija el usuario podamos ofrecer un resultado, estudiamos el género de todas las canciones de la muestra, al igual que la cantidad de relaciones que podíamos obtener de cada una de ellas.

Con el género queremos demostrar la variedad de la muestra y cómo de posible es relacionar canciones de distinto género entre sí. Si hubiésemos obtenido muy pocos géneros similares entre sí, la muestra no tendría un gran valor desde el punto de vista de esta explicación, pues no habríamos llegado a un resultado realmente interesante. Cabe destacar que no es un conteo exacto, ya que una canción puede tener más de un género o ninguno (por falta de documentación, no es posible catalogarlo en una categoría exacta, etc.). Sin embargo, el componente de variedad y representación musical no se ve afectado.




Figura 5.1: Gráfico resultado del estudio de géneros

En total hemos obtenido 81 géneros distintos para las canciones, entre los que destacan en gran principalmente subgéneros o géneros derivados del rock. El estilo más popular es **alternative rock**, el cual cuenta con un 22 % sobre el total, lo cual es una cantidad bastante alta en comparación con el resto. Le siguen **indie rock** y **rock music** con un 8,3 % y 3,9 % respectivamente.

Sin embargo, también encontramos otros géneros más distantes a los anteriores, como por ejemplo **rhythm & blues**, **soul**, **reggae**, **jazz** o **house music**. Todos estos son estilos dispares entres sí, lo que nos da la posibilidad de ver cómo de potentes pueden ser las relaciones y explicaciones que hemos obtenido y probar nuestro sistema para ver si es capaz de relacionar canciones muy diferentes o incluso opuestas.

### 5.3. Arquitectura de la aplicación

Como inicio tenemos varios scripts que nos ayudan a organizar y manejar mucho mejor los datos, como por ejemplo el script de limpieza y organización del dataset que, como ya hemos explicado antes, elimina cualquier tipo de valor nulo y lo ordena por popularidad, o el script de parseo, que nos permite acercarnos más a la sintaxis gramatical de Wikidata.

Como punto troncal, hemos desarrollado una librería que nos permite trabajar con la API de Wikidata. Hace uso de SparQL Library, la cual nos permite hacer uso del lenguaje SPARQL y hacer todo tipo de consultas a un punto. Esta librería se encarga de crear un punto de conexión a la API de Wikidata y de crear y ejecutar queries de consulta u obtención de datos.

Como siguiente punto tendríamos el modelo de la aplicación, que es una serie de clases que se encargan de ejecutar todo el proceso de obtención de datos, el cual es genérico para todas las canciones.

Cuenta con una lista de propiedades que son el objeto de estudio de cada canción y métodos para añadir o eliminar alguna de estas. Actualmente cuenta con un número de 21 propiedades totales, las cuales pueden tener su vez aún más de un modo recursivo.

Por último tenemos la clase principal, que es la que se encarga de hacer todas las llamadas al modelo de cada una de las dos canciones y artistas que son introducidos. También se encarga del manejo de excepciones y creación del CSV con las relaciones totales.





# Capítulo 6

## Conclusiones y Trabajo Futuro

### 6.1. Trabajo futuro

El esquema RDF y el uso de SPARQL para su uso y análisis puede ser muy potente y abarcar grandes cantidades de datos. En nuestro caso nos hemos centrado en trabajar con la herramienta y los datos de Wikidata por una cuestión de cantidad de información, fiabilidad y resultados obtenidos.

Con Wikidata hemos sido capaces de crear conexiones entre canciones con toda la información posible en cada una de sus respectivas páginas descriptivas. Sin embargo hay más opciones de donde recopilar más información sobre canciones y artistas.

En un principio intentamos obtener información que se alejaba un poco más de lo que hemos creado, que es un análisis musical. Hay otras opciones y datos que se pueden sacar sobre canciones, como por ejemplo las películas o series en las que aparecen como banda sonora, o también canciones que han sido emitidas durante grandes eventos como la Superbowl. El problema que tuvimos es que el proyecto en ese punto se desviaba de su rumbo original, ya que en Wikidata no había datos tan específicos para la gran mayoría de canciones y debíamos recurrir a otras fuentes.

El problema de otras bases de datos alternativas es que tampoco poseen ese tipo de información tan detallada, no siguen el modelo de datos RDF o tienen la información tan solo en casos muy concretos y sin una forma efectiva de acceder a ella a partir de nuestro dataset, como comprobamos al estudiar la posibilidad de utilizar **MusicBrainz** [6] para obtener las bandas sonoras en las que aparece una canción.

Otro aspecto en el que se puede trabajar para llegar a un trabajo mucho más completo y poder hacer una explicación de la relación de dos canciones, sería un estudio a nivel de usuario. En nuestro proyecto hemos hecho un análisis avanzado de las relaciones que tienen las entidades en un ámbito musical. Sin embargo, hay otro estudio posible que es el análisis de los usuarios que han escuchado esas canciones. Partimos de la base de que dos personas que escuchan una misma canción, pueden compartir parte de sus gustos musicales, y se pueden recomendar y crear relaciones conforme a su historial.

Cada usuario tiene un historial de temas escuchados, de hecho uno de los datasets que

obtuvimos al principio del proyecto era de este carácter. Si se hiciese un estudio individual de un usuario, se podrían analizar sus gustos musicales, canciones más escuchadas, últimos géneros más populares, etc. . .

Como ejemplo podemos seleccionar un usuario cuya mayoría de temas escuchados pertenecen al género pop, pero también cuenta con algunos pertenecientes al género indie durante los últimos meses. Si se encuentra una tendencia similar entre una cantidad significativa de usuarios, podríamos sacar una explicación que establezca una relación entre un tema de género pop y otro de género indie por la frecuencia con que aparecen estos géneros juntos entre las listas de temas escuchados de estos usuarios mencionados.

# Chapter **7**

## Introduction

Introduction to the subject area. This chapter contains the translation of Chapter 1.



# Chapter 8

## Conclusions and Future Work

Conclusions and future lines of work. This chapter contains the translation of Chapter 6.



# Bibliografía

*Y así, del mucho leer y del poco dormir, se le  
secó el cerebro de manera que vino a perder el  
juicio.*

*(modificar en Cascaras\bibliografia.tex)*

Miguel de Cervantes Saavedra

- [1] T. Berners-Lee, R. Fielding, L. Masinter, et al. Uniform resource identifiers (uri): Generic syntax, 1998.
- [2] T. Berners-Lee, J. Hendler, and O. Lassila. The semantic web. *Scientific american*, 284(5):34–43, 2001.
- [3] T. Berners-Lee, L. Masinter, M. McCahill, et al. Uniform resource locators (url). 1994.
- [4] W. contributors. Wikidata: Introduction, 2020. Accessed 13-April-2020.
- [5] M. B. T. W. R. J. Felix Miller, Martin Stiksel. Last.fm. Accessed 02-June-2020.
- [6] R. Kaye. Musicbrainz. Accessed 02-June-2020.
- [7] P. Saint-Andre and J. Klensin. Uniform resource names (urns). *Internet Engineering Task Force (IETF), RFC*, 8141, 2017.
- [8] S. Sakr, M. Wylot, R. Mutharaju, D. Le Phuoc, and I. Fundulaki. *Linked Data: Storing, Querying, and Reasoning*. Springer, 2018.





Apéndice **A**

Título del Apéndice A

Contenido del apéndice



Apéndice	<b>B</b>
----------	----------

Título del Apéndice B



Este texto se puede encontrar en el fichero Cascaras/fin.tex. Si deseas eliminarlo, basta con comentar la línea correspondiente al final del fichero TFMTeXiS.tex.

*–¿Qué te parece desto, Sancho? – Dijo Don Quijote –  
Bien podrán los encantadores quitarme la ventura,  
pero el esfuerzo y el ánimo, será imposible.*

*Segunda parte del Ingenioso Caballero  
Don Quijote de la Mancha  
Miguel de Cervantes*

*–Buena está – dijo Sancho –; fírmela vuestra merced.  
–No es menester firmarla – dijo Don Quijote–,  
sino solamente poner mi rúbrica.*

*Primera parte del Ingenioso Caballero  
Don Quijote de la Mancha  
Miguel de Cervantes*

